

NLLR

Toteutusdokumentti

Leo Leppänen

24. helmikuuta 2014

Sisältö

1	Algoritmit	2
1.1	Argmax.single	2
1.2	Argmax.multiple	3
1.3	TFIDF	5
1.4	NLLR	7
2	Tietorakenteet	10
2.1	ArrayList	10
2.2	HashMap	15
2.3	HashSet	22

1 Algoritmit

1.1 Argmax.single

```
1 public Result<T> single(Algorithm algorithm, ArrayList<T> args, Object
   [] constants){
2
3     Object[] argList = new Object[constants.length + 1];
4     System.arraycopy(constants, 0, argList, 1, constants.length);
5     argList[0] = args.get(0);
6
7     double maxVal = algorithm.calculate(argList);
8     T maxArg = args.get(0);
9
10    for (int i = 1; i < args.size(); i++) {
11        argList[0] = args.get(i);
12        double result = algorithm.calculate(argList);
13
14        if (maxVal < result){
15            maxVal = result;
16            maxArg = args.get(i);
17        }
18    }
19    return new Result(maxArg, maxVal);
20 }
```

Kuva 1: Argmax.single()

Tilavaativuus

Tilavaativuus on $\mathcal{O}(1)$, sillä algoritmit käyttää vakiomäärää muuttujia ja tulostaa aina yhden Result-olion.

Aikavaativuus

Argmax suorittaa syötteenään saamansa algoritmin kerran per syöteenä saadun argumenttilistan argumentti, joten aikavaativuus on $\mathcal{O}(A \times n)$, missä n on maksimoitavan argumentin kandidaattien määrä ja A on suoritettavan algoritmin aikavaativuus.

1.2 Argmax.multiple

```
1 public ArrayList<Result<T>> multiple(Algorithm algorithm, int amount,
   ArrayList<T> args, Object[] constants){
2     ArrayList<Result<T>> results = new ArrayList<>();
3
4     Object[] argList = new Object[constants.length + 1];
5     System.arraycopy(constants, 0, argList, 1, constants.length);
6     for (T arg : args){
7         argList[0] = arg;
8         double result = algorithm.calculate(argList);
9         if (results.size() < amount){
10             results.add(new Result(arg, result));
11             sort(results);
12         } else if (results.get(amount-1).getValue() < result){
13             results.remove(amount-1);
14             results.add(new Result(arg, result));
15             sort(results);
16         }
17     }
18     return results;
19 }
```

Kuva 2: Argmax.multiple()

```

1 private void sort(ArrayList<Result<T>> results){
2     for (int i = 1; i < results.size(); i++) {
3         Result x = results.get(i);
4         int j = i;
5         while (j > 0 && results.get(j-1).getValue() < x.getValue()){
6             results.set(j, results.get(j-1));
7             j = j-1;
8         }
9         results.set(j, x);
10    }
11 }

```

Kuva 3: Argmax.sort()

Tilavaativuus

Tilavaativuus on $\mathcal{O}(n)$, sillä kerrallaan muistissa pidetään korkeintaan $n + 1$ Result-oliota sekä vakiomäärää muita muuttujia.

Aikavaativuus

Algoritmi suorittaa syötteenä saadun A aikavaativuuksisen algoritmin n kertaa, jolloin tältä osin aikavaativuus on $\mathcal{O}(A \times n)$. Lisäksi pahimmillaan n kertaa kutsutaan metodia sort(), joka järjestää tuloslistan.

Järjestysalgoritmina toimii InsertionSort. Järjestysalgoritmin valintaan vaikutti uniikki konteksti: jokaisella järjestyskerralla kaikki paitsi yksi alkio ovat valmiina oikeilla paikoillaan. Lisäksi järjestettävät taulukot erittäin pienikokoisia. Näissä tapauksissa InsertionSort on nopein ja tehokkain¹. Tässä erityistapauksessamme aikavaativuus on lähempänä $\mathcal{O}(n)$ kuin $\mathcal{O}(n^2)$ ja tilavaativuus on $\mathcal{O}(1)$.

¹<http://dl.acm.org/citation.cfm?doid=359024.359026>

1.3 TFIDF

```
1 public static double tfidf(String token, Document query, Corpus
   reference){
2     int tf = query.getFrequency(token);
3     double idf = idf(reference, token);
4     return tf * idf;
5 }
```

Kuva 4: Tfidf.tfidf()

```
1 public static double idf(Corpus reference, String token) {
2     int totalDocs = reference.getDocuments().size();
3     int docsContainingTerm = reference.numOfDocsContainingToken(token);
4
5     return Math.log( (double) totalDocs / docsContainingTerm);
6 }
```

Kuva 5: Tfidf.idf()

Tilavaativuus

Algoritmin tilavaativuus on $\mathcal{O}(1)$, sillä se käyttää syötteen koosta riippumatta vain vakiomäärää omia muuttujia.

Aikavaativuus

Algoritmin aikavaativuus voidaan laskea kahdessa osassa: *IDF*-algoritmin osuus sekä *TF-IDF*-algoritmin kokonaisaikavaativuus.

IDF-osion aikavaativuus on $\mathcal{O}(1)$. Rivin `reference.getDocuments().size();` suorittaminen vie $\mathcal{O}(1)$, sillä `reference.getDocuments()` palauttaa *ArrayList*-olion ajassa $\mathcal{O}(1)$ ja tältä oliolta voidaan edelleen kysyä ajassa $\mathcal{O}(1)$ sen kokoa. Kutsun `reference.numOfDocsContainingToken(token)` aikavaativuus on myöskin $\mathcal{O}(1)$, sillä kutsussa suoritetaan *HashMap*-olion `containsKey()`- ja `get()`-metodit,

jotka molemmat ovat $\mathcal{O}(1)$. Myös lopussa suoritettava $\text{Math.log}(\text{double})$ $\text{totalDocs} / \text{docsContainingTerm}$) vie aikaa $\mathcal{O}(1)$, jolloin IDF -osion aikavaativuus on $\mathcal{O}(1 + 1 + 1) = \mathcal{O}(1)$

$TF-IDF$ suorittaa yhden IDF -kutsun lisäksi yhden $\text{query.getFrequency(token)}$ -kutsun, joka pahimmassa tapauksessa suorittaa ensin $\text{HashMap.containsKey()}$ -kutsun ja sen jälkeen HashMap.get() -kutsun, joiden molempien aikavaativuus on $\mathcal{O}(1)$. Lisäksi suoritetaan lopuksi vakioaikainen laskutoimitus. Kokonaisuudessaan aikavaativuus on siis $\mathcal{O}(1 + 1) = \mathcal{O}(1)$

1.4 NLLR

```
1 public double calculateNllr(Document query, Corpus candidate){
2     double nllr = 0;
3
4     Object[] constants = {query, corpus};
5     ArrayList<Result<String>> results = new Argmax().multiple(
6         new Tfidf(),
7         NUMBER_OF_TOKENS_TO_ANALYZE,
8         query.getUniqueTokens().toArray(),
9         constants);
10
11     for(Result<String> result : results){
12         String uniqueToken = result.getArgument();
13
14         double tokenProbQuery = calculateTokenProbability(uniqueToken,
15             query);
16         double tokenProbCandidate = calculateTokenProbability(uniqueToken,
17             candidate);
18         double tokenProbCorpus = calculateTokenProbability(uniqueToken,
19             corpus);
20
21         nllr += tokenProbQuery * Math.log(tokenProbCandidate /
22             tokenProbCorpus);
23     }
24
25     return nllr;
26 }
```

Kuva 6: Nllr.nllr()

```

1 public double calculateTokenProbability(String token, BagOfWords
   bagOfWords) {
2     double prob = (double) bagOfWords.getFrequency(token) / bagOfWords.
       getTotalTokens();
3     if (prob == 0){
4         return NONZERO;
5     } else {
6         return prob;
7     }
8 }

```

Kuva 7: Nllr.calculateTokenProbability()

Tilavaativuus

$\mathcal{O}(1)$, sillä algoritmi käyttää syötteensä lisäksi vain vakiomäärän tilaa bestTokens-taulukon sekä välitulokset tallentavien muuttujien muodossa.

Aikavaativuus

Algoritmi määrittää aluksi Argmax:lla vakiomäärän parhaan TF-IDF arvon saavia sanoja, joille sen jälkeen kullekin suoritetaan useita $\mathcal{O}(1)$ aikavaativuuksisia calculateTokenPropability-komentoja. Täten aikavaativuus on mallia

$$\mathcal{O}(\text{Argmax.multiple}(\text{TFIDF}, n) \times a + a \times (3 \times \text{calculateTokenProbability} + 1))$$

missä a on vakio, oletusarvoisesti 10 ja n on syötteenä saadun dokumentin sanojen määrä. Koska TF-IDF aikavaativuus on $\mathcal{O}(1)$ ja a on vakio, voidaan lauseketta sieventää seuraavaan muotoon: $\mathcal{O}(n + \text{calculateTokenProbability})$.

Metodin *calculateTokenPropability* aikavaativuus puolestaan on $\mathcal{O}(1)$, sillä sen suorittamat metodikutsut ovat vakioaikaisia (*HashMap.containsKey()*, *HashMap.get()*). Näiden metodikutsujen lisäksi suoritetaan vain vakioaikaisia laskentakäskyjä.

Täten *NLLR*:n aikavaativuus on $\mathcal{O}(n + \text{calculateTokenProbability})$, missä n on syötteenä saadun dokumentin sanojen määrä. Näin alhainen aikavaativuus on kuitenkin mahdollista vain, koska suurin osa laskennasta suoritetaan jo dokumentteja korpukseseen lisättäessä.

2 Tietorakenteet

2.1 ArrayList

Tilavaativuus

ArrayList käyttää sisäisesti taulukkoa, joka on korkeintaan vakiokertoimen verran sen sisältämien alkioden lukumäärää n suurempi. Lisäksi käytetään vakiomäärää kirjanpitomuuttujia. Täten pahimman tapauksen tilavaativuus on mallia $\mathcal{O}(x \times n)$, missä x on vakio ja tilavaativuus voidaan siten kirjoittaa muotoon $\mathcal{O}(n)$.

Aikavaativuus

Analysoidaan aikavaativuuden tärkeimpien komentojen osalta erikseen:

get(): Aina $\mathcal{O}(1)$, sillä teemme vakiomäärän vakioaikaisia kutsuja.

```
1 public T get(int index){  
2     if (validIndex(index)){  
3         return (T) array[index];  
4     }  
5     throw new IndexOutOfBoundsException();  
6 }
```

Kuva 8: ArrayList.get()

add(): Pahimmassa tapauksessa $\mathcal{O}(n)$, mikäli joudumme kasvattamaan taustalla olevan taulukon kokoa. Koska taulukon koko kuitenkin kasvaa kahden potensseissa, joudumme tekemään tämän muutoksen vain n lisäyksen välein ja amortisoitu aikavaativuus on $\mathcal{O}(1)$

```

1 public void add(T value) {
2     array[size] = value;
3     size++;
4     modCount++;
5     checkCapacity();
6 }

```

Kuva 9: ArrayList.add()

size(): $\mathcal{O}(1)$, sillä suoritamme vain yhden vakioaikaisen komennon.

```

1 public int size() {
2     return this.size;
3 }

```

Kuva 10: ArrayList.size()

indexOf(): Käymme pahimmassa tapauksessa koko listan suorittaen jokaiselle alkiolle vakiomäärän $\mathcal{O}(1)$ aikavaativuuksisia vertailuja, sekä lopulta suorittaen $\mathcal{O}(1)$ aikaisen palautuskutsun, jolloin aikavaativuus on $\mathcal{O}(n)$.

```

1 public int indexOf(T value) {
2     for (int i = 0; i < size; i++) {
3         if ((value == null && array[i] == null) || (value != null && value.
4             equals(array[i]))) {
5             return i;
6         }
7     }
8     return -1;

```

Kuva 11: ArrayList.indexOf()

contains(): Kutsumme metodia *indexOf()* jonka aikavaativuus on $\mathcal{O}(n)$, ja suoritamme vakioaikaisen palautuksen. Täten aikavaativuus on yhteensä $\mathcal{O}(n)$.

```

1 public boolean contains(T value){
2     return indexOf(value) != -1;
3 }

```

Kuva 12: ArrayList.contains()

isEmpty(): Suoritamme vakioaikaisen tarkastuksen ja palautamme sen tuloksen. Lopputuloksena aikavaativuus $\mathcal{O}(1)$.

```

1 public boolean isEmpty() {
2     return size == 0;
3 }

```

Kuva 13: ArrayList.isEmpty()

clear(): Suoritamme vakiomäärän vakioaikaisia operaatioita, joten aikavaativuus on $\mathcal{O}(1)$.

```

1 public void clear() {
2     array = new Object[DEFAULT_SIZE];
3     limit = DEFAULT_SIZE;
4     modCount++;
5     size = 0;
6 }

```

Kuva 14: ArrayList.clear()

remove(int index): Tarkistamme ensin ajassa $\mathcal{O}(1)$ onko indeksi käytössä. Tämän jälkeen siirrämme annettuun indeksiin ja sitä seuraavan indeksin alkion ja siirrymme seuraavaan indeksiin, jossa toistamme saman operaation. Täten pahimmassa tapauksessa (indeksi = 0) käymme läpi koko listan tehden $\mathcal{O}(1)$ aikavaativuuksisia sijoitusoperaatioita. Lopuksi tarkistamme onko listan kokoon tehtävä muutoksia, joka pahimmassa tapauksessa kestää $\mathcal{O}(n)$. Täten pahimman tapauksen aikavaativuus on $\mathcal{O}(n + n) = \mathcal{O}(n)$. Jälkimmäinen listan

koon muutos amortisoituu aikavaativuuteen $\mathcal{O}(1)$, mutta tämä ei vaikuta lopullisen aikavaativuuden \mathcal{O} -notaatioon joka on jokatapauksessa $\mathcal{O}(n)$.

```
1 public void remove(int index){
2     if (!validIndex(index)){
3         throw new IndexOutOfBoundsException();
4     }
5
6     while(validIndex(index)){
7         array[index] = array[index+1];
8         index++;
9     }
10    size--;
11    modCount++;
12    checkCapacity();
13 }
```

Kuva 15: ArrayList.remove(int index)

remove(T value): Pahimmassa tapauksessa suoritamme ensin $\mathcal{O}(n)$ aikaisen *indexOf*-kutsun ja sen jälkeen kutsumme $\mathcal{O}(n)$ aikaista *remove(int index)*-metodia. Täten pahimman tapauksen aikavaativuus on $\mathcal{O}(n + n) = (O)n$.

```
1 public void remove(T value){
2     int index = indexOf(value);
3     if (index != -1){
4         remove(index);
5     }
6 }
```

Kuva 16: ArrayList.remove(T value)

set(): Aikavaativuus on $\mathcal{O}(1)$, sillä suoritamme vain vakiomäärän vakioaikaisia operaatioita.

```

1 public void set(int index, T value){
2     if (index <= size && index >= 0){
3         array[index] = value;
4     }
5 }

```

Kuva 17: ArrayList.set()

Taustalla olevan taulukon koon muutokset vievät, kuten yllä esitettyä $\mathcal{O}(n)$, sillä luomme uuden taulukon ajassa $\mathcal{O}(1)$ ja käymme aiemman taulukon läpi ajassa $\mathcal{O}(n)$, suorittaen jokaisella n alkiolle $\mathcal{O}(n)$ aikavaativuudksisen sijoitusoperaation uuteen taulukkoon. Tämän lisäksi suoritetaan vain vakiomäärä vakioaikaisia operaatioita.

```

1 private void changeCapacity(int newLimit){
2     Object[] newArray = new Object[newLimit];
3     int smallerLimit = Math.min(newLimit, limit);
4     System.arraycopy(array, 0, newArray, 0, smallerLimit);
5     array = newArray;
6     limit = newLimit;
7 }

```

Kuva 18: ArrayList.changeCapacity()

2.2 HashMap

Tilavaativuus

HashMap:n tilavaativuus on pahimmassa tapauksessa, kaikkien hajautusarvojen osuessa yhteen hajautustaulun ylivuotoketjuun, $\mathcal{O}(\text{taulukon}_k\text{oko} + n)$, missä $\text{taulukon}_k\text{oko}$ on hajautustaulun taustalla olevan taulukon koko, ja n ym. ylivuotoketjussa olevien alkioden, ja samalla taulukon kaikkien alkioden määrä. $\text{taulukon}_k\text{oko}$ puolestaan on pahimmassa tapauksessa, $x \times n$, missä x on jokin vakio, meidän tapauksessamme noin 2. Täten tilavaativuus on pahimmillaan $\mathcal{O}(2n) = \mathcal{O}(n)$. n puolestaan on tarkemmin sanoen muotoa $|K| + |V|$, missä $|K|$ on hajautustaulun avainten tilavaativuus ja $|V|$ hajautustaulun arvojen tilavaativuus. Täten Lopullinen tilavaativuutemme on $\mathcal{O}(|K| + |V|)$.

Aikavaativuus

Analysoimme aikavaativuuden erikseen jokaiselle metodille.

get(): Pahimmassa tapauksessa kaikki hajautustaulun alkiot ovat samassa ylivuotoketjussa, jolloin löydämme oikean ylivuotoketjun ajassa $\mathcal{O}(1)$, minkä jälkeen käymme koko ketjun läpi ajassa $\mathcal{O}(n)$. Täten pahimman tapauksen aikavaativuus on $\mathcal{O}(n)$. Amortisoidusti hajautustaulun arvot kuitenkin jakautuvat tasaisesti koko taulukon alueelle, jolloin aikavaativuus on $\mathcal{O}(1 + x)$, missä x on keskimääräinen ylivuotoketjun pituus. Tämän ollessa yksi tai hyvin lähellä sitä, on amortisoitu aikavaativuus siten käytännössä $\mathcal{O}(1)$.

```

1 public V get(K key){
2     // Determine in which bucket the Entry should be in
3     int index = getIndex(key, size);
4     Entry entry = this.array[index];
5
6     //Go thru that bucket, looking for the key
7     while(entry != null) {
8         if (entry.getKey().equals(key)){
9             return (V) entry.getValue();
10        }
11        entry = entry.getNext();
12    }
13
14    //If bucket is empty or no key found in bucket, return null
15    return null;
16 }

```

Kuva 19: HashMap.get()

HashMap.put(): Löydämme oikean ylivuotolistan ajassa $\mathcal{O}(1)$. Pahimmassa tapauksessa kaikki hajautustaulun arvot ovat samassa ylivuotoketjussa, jolloin joudumme käymään läpi koko ylivuotoketjun ajassa $\mathcal{O}(n)$ ennen kuin lisäämme arvon ketjun alkuun ajassa $\mathcal{O}(1)$.

Tämän jälkeen joudumme vielä pahimmassa tapauksessa uudelleenhajauttamaan koko hajautustaulun ajassa $\mathcal{O}(n)$. Täten pahimman tapauksen aikavaativuus on $\mathcal{O}(n + n) = \mathcal{O}(n)$. Keskimäärin joudumme kuitenkin uudelleenhajauttamaan taulun n lisäyksen välein, joten amortisoidusti lisäyksen osuus aikavaativuudesta on $\mathcal{O}(1)$.

Samoin yhdessä ylivuotoketjussa on amortisoidusti 0 (tai 1, kuitenkin käytännössä hyvin lähellä nollaa) alkioita, jolloin lisäyksenkin kesto on amortisoidusti $\mathcal{O}(1)$. Täten koko amortisoitu aikavaativuus on $\mathcal{O}(1)$.


```

1 public void put(K key, V value){
2     //Determine which bucket the key belongs to
3     int index = getIndex(key, size);
4
5     //If the bucket is empty, add the Entry as a new bucket
6     if (this.array[index] == null){
7         Entry e = new Entry<>(key, value);
8         this.array[index] = e;
9     } else {
10        //An existing bucket was found, go thru the bucket looking for the
        key
11        Entry entry = this.array[index];
12        while (entry != null){
13            if (entry.getKey().equals(key)){
14                //Found key, overwrite current value and exit
15                entry.setValue(value);
16                return;
17            }
18            entry = entry.getNext();
19        }
20
21        //Didn't find key in bucket, add a new entry to start of bucket
22        Entry newEntry = new Entry<>(key, value);
23        newEntry.setNext(array[index]);
24        array[index] = newEntry;
25    }
26    entries++;
27    modCount++;
28    checkCapacity();
29 }

```

Kuva 20: HashMap.put()

HashMap.remove(): Löydämme oikean ylivuotolistan ajassa $\mathcal{O}(1)$.
Pahimmassa tapauksessa, kaikkien alkioiden ollessa samassa ylivuotolistassa,

joudumme jälleen käymään ylivuotolistaa läpi ajassa $\mathcal{O}(n)$. Itse poisto-operaatio on kuitenkin $\mathcal{O}(1)$, sillä suoritamme vakiomäärän vakioaikaisia operaatioita.

Samoin kuin yllä, mahdollinen taustalistan koon muutos on pahimmassa tapauksessa $\mathcal{O}(n)$, mutta amortisoituu aikaa $\mathcal{O}(1)$. Samoin yllä esitetyllä logiikalla ylivuotolistan läpikäynti vie keskimäärin $\mathcal{O}(1)$, jolloin saamme pahimman tapauksen aikavaativuudeksi $\mathcal{O}(n)$, mutta amortisoiduksi aikavaativuudeksi $\mathcal{O}(1)$.

```

1 public void remove(K key){
2     //Find the correct bucket
3     int index = getIndex(key, size);
4     Entry e = array[index];
5
6     //If no bucket present, just exit
7     if (e == null){
8         return;
9     }
10
11    //Search the bucket for the key
12    Entry previous = null;
13    while (e != null){
14        Entry next = e.getNext();
15        if (e.getKey().equals(key)){
16            //Found our entry!
17            //If entry is head, update array, else update prev's next().
18            if (previous == null){
19                array[index] = e.getNext();
20            } else {
21                previous.setNext(next);
22            }
23
24            entries--;
25            modCount++;
26            checkCapacity();
27            return;
28        }
29        previous = e;
30        e = next;
31    }
32 }

```

Kuva 21: HashMap.remove()

HashMap.containsKey(): Oikea ylivuotoketju selviää ajassa $\mathcal{O}(1)$. Pahimmassa tapauksessa joudumme käymään läpi koko ylivuotoketjun ajassa $\mathcal{O}(n)$ tehden kullekin alkion vakiomäärän vakioaikaisia operaatioita ajassa $\mathcal{O}(1)$. Pahimman tapauksen aikavaativuus on siis $\mathcal{O}(n)$. Amortisoidusti metodin aikavaativuus kuitenkin on - kuten yllä - $\mathcal{O}(1)$.

```
1 public boolean containsKey(K key){
2     if (key == null){
3         return false;
4     }
5
6     int index = getIndex(key, size);
7     Entry e = array[index];
8     while (e != null){
9         if (e.getKey().equals(key)){
10             return true;
11         }
12         e = e.getNext();
13     }
14     return false;
15 }
```

Kuva 22: HashMap.containsKey()

HashMap.getIndex(): Suoritamme aina vakiomäärän vakioaikaisia kutsuja, joten aikavaativuus on aina $\mathcal{O}(1)$. Metodin toimintalogiikkaa on avattu enemmän JavaDocissa.

```

1 private int getIndex(K key, int size){
2     int hash = key.hashCode();
3     hash ^= (hash >>> 20) ^ (hash >>> 12) ^ (hash >>> 7) ^ (hash >>> 4);
4
5     int index = hash & (size - 1);
6     return index;
7 }

```

Kuva 23: HashMap.getIndex()

Emme esitä tässä taustataulukon koon muutosten koodia sen pituuden vuoksi. Käytännössä kuitenkin tarkistamme ajassa $\mathcal{O}(1)$ onko muutokselle tarvetta. Mikäli tarvetta on, luomme ajassa $\mathcal{O}(1)$ uuden taulukon josta tulee uusi taustataulukkomme. Tämän jälkeen suoritamme uudelleenhajautuksen.

Uudelleenhajautuksessa käymme läpi kaikki taulukon n alkiota ajassa $\mathcal{O}(n)$, suorittaen jokaiselle vakiomäärän komentoja joilla alkiolle selvitetään indeksi uudessa taulukossa ajassa $\mathcal{O}(1)$ ja sijoitetaan se oikean indeksin ylivuotoketjun alkuun ajassa $\mathcal{O}(1)$. Täten uudelleenhajautus vie kokonaisuutenaan aikaa $\mathcal{O}(n)$.

2.3 HashSet

HashSet-toteutuksemme on käytännössä wrapperi *HashMap*-rakenteen ympärille, joten aika- ja tilavaativuutemme ovat erittäin vastaavat.

Tilavaativuus

Tilavaativuus on sama kuin n alkia sisältävän *HashMap*-tietorakenteen, kuitenkin siten että $|V|$ on $x \times n$, missä x on vakio ja n on setin sisältämien alkoiden määrä. Tämä johtuu siitä kuinka asetamme kaikkii *HashMap*in avain-arvo -pareihin arvoksi viitteen samaan *DUMMY*-olioon.

Lisäksi käytämme vakiomäärää vakiokokoisia apumuuttujia, jotka eivät vaikuta lopulliseen tilavaativuuteemme, joka on siis $\mathcal{O}(|K| + n)$, missä $|K|$ on setin sisältämä arvojoukko ja n on *DUMMY*-olio ja k kappaletta viitteitä siihen.

Aikavaativuus

Tarkastellaan aikavaativuuksia erikseen jokaiselle metodille.

HashSet.add() tarkistaa ensin (keskimäärin) ajassa $\mathcal{O}(1)$ onko arvo jo setissä, ja jos ei ole niin lisää sen edelleen (keskimäärin) ajassa $\mathcal{O}(1)$. Täten keskimääräinen aikavaativuus on $\mathcal{O}(1)$.

Pahin tapaus on kuitenkin $\mathcal{O}(n + n) = \mathcal{O}(n)$, mikäli kaikki arvot ovat hajautustaulun samassa ylivuotoketjussa.

```

1 public void add(E e){
2     if (e != null){
3         if (!map.containsKey(e)) {
4             map.put(e, DUMMY);
5             size++;
6             modCount++;
7         }
8     }
9 }

```

Kuva 24: HashSet.add()

HashSet.remove() tarkistaa ensin (keskimäärin) ajassa $\mathcal{O}(1)$ onko arvo rakenteessa ja mikäli on, poistaa sen (keskimäärin) ajassa $\mathcal{O}(1)$.

Samoin kuin yllä, pahimmassa tapauksessa taustalla olevan *HashMap*in kaikki arvot ovat samassa ylivuotolistassa ja molemmat operaatiot vievät $\mathcal{O}(n)$ aikaa. Täten pahimman tapauksen aikavaativuus on $\mathcal{O}(n + n) = \mathcal{O}(n)$, mutta amortisoitu aikavaativuus on $\mathcal{O}(1)$.

```

1 public void remove(E e){
2     if (e != null){
3         if (map.containsKey(e)) {
4             map.remove(e);
5             size--;
6             modCount++;
7         }
8     }
9 }

```

Kuva 25: HashSet.remove()

HashSet.contains() on vain wrapperi *HashMap.containsKey()*-metodille ja sen aikavaativuus on sama kuin em. metodilla, eli pahimmassa tapauksessa $\mathcal{O}(n)$, mutta amortisoidusti $\mathcal{O}(1)$.

```
1 public boolean contains(E e){
2     return map.containsKey(e);
3 }
```

Kuva 26: HashSet.contains()

HashSet.size() suorittaa vakiomäärän vakioaikaisia operaatioita ja on siten aikavaativuudeltaan $\mathcal{O}(1)$.

```
1 public int size(){
2     return size;
3 }
```

Kuva 27: HashSet.size()

HashSet.isEmpty() suorittaa vakiomäärän vakioaikaisia operaatioita ja on siten aikavaativuudeltaan $\mathcal{O}(1)$.

```
1 public boolean isEmpty(){
2     return size == 0;
3 }
```

Kuva 28: HashSet.isEmpty()

Metodit *HashSet.removeAll()* ja *HashSet.addAll()* suorittavat molemmat n kertaa oman yksittäismetodinsa ja vastaavat siten n kappaletta kyseisiä kutsuja.